



# **Automatische Klassifikation von Thorax-Röntgenbildern zur Erkennung von Pneumonie und Tuberkulose**

Projektbericht

**Gruppe:**  
Felix Zauner, Timofey Luzin

**Klasse & Schuljahr:**  
5AHETS 2025/26

**Abgabe:**  
15.12.2025

## Inhaltsverzeichnis

<b>1 Einleitung</b>	<b>2</b>
<b>2 Datensatzbeschreibung</b>	<b>3</b>
<b>3 Datenaufbereitung</b>	<b>4</b>
<b>4 Modellauswahl und -training</b>	<b>5</b>
4.1 Modellauswahl . . . . .	5
4.2 Modelltraining . . . . .	6
4.3 Code-Dokumentation . . . . .	8
4.4 Probleme und Herausforderungen . . . . .	10
<b>5 Evaluation des Modells</b>	<b>11</b>
<b>6 Probleme und Herausforderungen im gesamten Projekt</b>	<b>13</b>
6.1 Technische Herausforderungen . . . . .	13
6.2 Modellierungsprobleme . . . . .	13
<b>7 Schlussfolgerung und Reflexion</b>	<b>14</b>
<b>8 Quellen und Literaturverzeichnis</b>	<b>15</b>
<b>9 Anhang</b>	<b>16</b>

## 1 Einleitung

In diesem Projektbericht wird die Entwicklung eines Modells zur automatischen Klassifikation von Thorax-Röntgenbildern zur Erkennung von Pneumonie und Tuberkulose beschrieben.

Die KI-basierte Bildanalyse hat in den letzten Jahren erhebliche Fortschritte gemacht und bietet vielversprechende Möglichkeiten zur Unterstützung medizinischer Diagnosen. Manche Experten sehen in der automatischen Bildanalyse sogar das Potenzial, die Genauigkeit und Effizienz von Diagnosen zu verbessern, insbesondere in ressourcenarmen Umgebungen.

Ziel dieses Projekts ist es, ein Modell zu entwickeln, das in der Lage ist, Thorax-Röntgenbilder zu analysieren und zwischen gesunden Patienten, Patienten mit Pneumonie und Patienten mit Tuberkulose zu unterscheiden.

Der Bericht gliedert sich in mehrere Abschnitte, die den gesamten Entwicklungsprozess abdecken, von der Datensammlung und -aufbereitung über die Modellauswahl und das Training bis hin zur Evaluation des Modells. Abschließend werden die Herausforderungen und Probleme, die während des Projekts aufgetreten sind, sowie eine Reflexion über die Ergebnisse und mögliche zukünftige Verbesserungen diskutiert.

## 2 Datensatzbeschreibung

Der Datensatz stammt beinhaltet insgesamt 25.600 Thorax-Röntgenbilder, die in drei Klassen unterteilt sind: Gesunde Patienten, Patienten mit Pneumonie und Patienten mit Tuberkulose. Die Bilder sind schon in Trainings-, Validierungs- und Testsets aufgeteilt. In unserer Anwendung verwenden wir *ausschließlich* das *Trainingsset* und das *Testset*.

Die Bilder liegen im JPEG-Format vor und haben keine standartisierte Auflösung. Hier ist eine Übersicht über die Struktur des Datensatzes dargestellt:

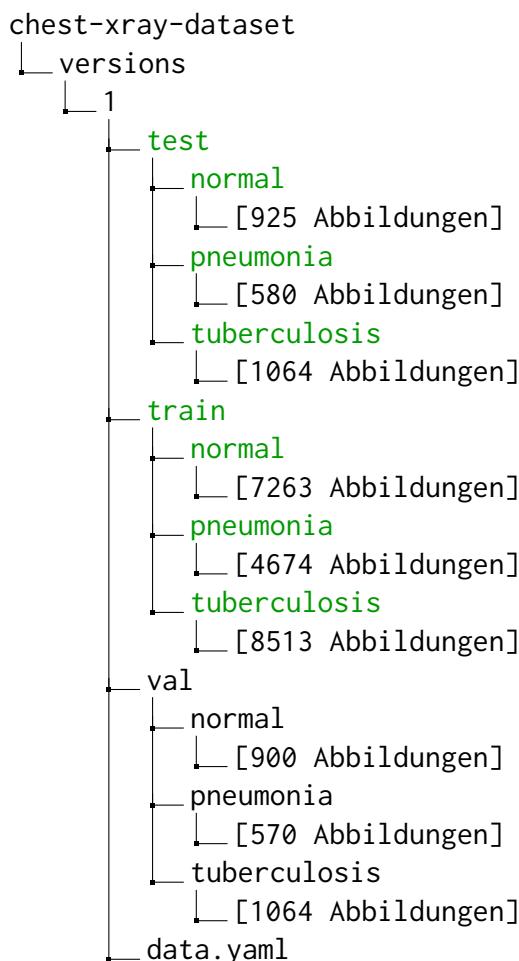


Abbildung 1: Struktur des Datensatzes

Das Dataset wurde von Kaggle bereitgestellt und ist öffentlich zugänglich unter folgendem Link:  
<https://www.kaggle.com/datasets/muhammadrehan00/chest-xray-dataset>

### 3 Datenaufbereitung

Aufgrund der unterschiedlichen Auflösungen der Bilder im Datensatz war eine sorgfältige Datenaufbereitung erforderlich, um eine konsistente Eingabe für das Modell zu gewährleisten.

Die Bilder wurden sowohl auf eine einheitliche Größe von 128x128 Pixel skaliert, als auch in schwarz-weiß umgewandelt, um die Verarbeitung zu erleichtern und die Leistung des Modells zu optimieren.

Dies wurde mit der OpenCV-Bibliothek in Python durchgeführt.

Das folgende Code-Snippet zeigt die Implementierung der Bildskalierung und der Umwandlung in Graustufen:

```
1 import cv2
2 # Transform and load images
3 def load_images(folder, label, img_size=(128, 128)):
4     X, y = [], []
5
6     for file in os.listdir(folder):
7         path = os.path.join(folder, file)
8         img = cv2.imread(path, cv2.IMREAD_GRAYSCALE)
9         img = cv2.resize(img, img_size)
10        X.append(img)
11        y.append(label)
12
13    return X, y
```

Listing 1: Image Resizing und Grayscale Conversion

## 4 Modellauswahl und -training

### 4.1 Modellauswahl

Zu Beginn des Projektes wurde der bereits im Exposé genannte MLP Classifier implementiert und trainiert.

Nach ersten Tests und Evaluierungen wurde jedoch festgestellt, dass die Ergebnisse nicht zufriedenstellend waren.

Daraufhin wurde ein zweiter MLP Classifier mit mehr Schichten und optimierten Hyperparametern ausprobiert, um die Leistung zu verbessern.

Auf der Suche nach weiteren Verbesserungen wurde auch ein SVM (Support Vector Machine) Classifier mit & ohne Feature Extraction getestet.

Die folgenden Modelle wurden evaluiert:

- **MLP Classifier:**

Ein mehrschichtiger Perzeptron-Klassifikator (MLP) ist ein Feedforward-Neuronales Netzwerk, das aus mehreren Schichten von Neuronen besteht: einer Eingabeschicht, einer oder mehreren versteckten Schichten und einer Ausgabeschicht. Jede Verbindung zwischen den Neuronen hat ein Gewicht, das während des Trainings angepasst wird. Der MLP verwendet Aktivierungsfunktionen (z.B. ReLU, Sigmoid), um Nichtlinearitäten einzuführen und komplexe Muster in den Daten zu lernen. Das Training erfolgt durch Backpropagation und Optimierungsalgorithmen wie Adam oder SGD, um die Gewichte zu aktualisieren und die Vorhersagegenauigkeit zu maximieren.

- **SVM ohne Feature Extraction**

Ein Support Vector Machine (SVM) ist ein klassischer, margin-basierter Klassifikator. Grob funktioniert er so: die SVM sucht eine (lineare) Trennfläche im Merkmalsraum, die den Abstand (Margin) zwischen den Klassen maximiert; nur die Trainingspunkte, die die Margin am stärksten bestimmen (Support-Vectors), beeinflussen das Modell. Für nichtlineare Probleme wird der Kernel-Trick (z.B. RBF, polynomial) genutzt, der implizit in einen höherdimensionalen Raum abbildet, sodass eine lineare Trennung dort möglich wird. Mit dem Regularisierungsparameter C lässt sich die Toleranz gegenüber Fehlklassifikationen (Soft-Margin) steuern.

## 4.2 Modelltraining

Das Training der Modelle erfolgte mit dem vorbereiteten Datensatz. Verschiedene Hyperparameter wurden getestet, um die Leistung zu optimieren.

- MLP Classifier:

Der Code initialisiert und trainiert einen mehrschichtigen Perzeptron-Klassifikator (MLP) mit einem versteckten Layer. Dazu werden die Bilddaten zunächst abgeflacht, standardisiert und anschließend zum Trainieren des Modells verwendet.

```

1 # Train MLP Classifier
2 mlp = MLPClassifier(hidden_layer_sizes=(50,), max_iter=50,
                      alpha=1e-4, solver='adam', verbose=True, random_state=912)
3
4 # Flatten images to (n_samples, n_features) because
   # MLPClassifier expects 2D input
5 X_train_flat = X_train.reshape(X_train.shape[0], -1)
6 X_test_flat = X_test.reshape(X_test.shape[0], -1)
7
8 # Scale features
9 scaler = StandardScaler()
10 X_train_scaled = scaler.fit_transform(X_train_flat)
11 X_test_scaled = scaler.transform(X_test_flat)
12
13 # Fit model
14 mlp.fit(X_train_scaled, y_train)

```

Listing 2: MLP Classifier

- MLP Classifier mit mehr Schichten:

Der Code definiert und trainiert einen optimierten MLP-Klassifikator mit zwei versteckten Schichten und erhöhter Modellkapazität. Durch angepasste Trainingsparameter wird eine stabilere und leistungsfähigere Klassifikation auf den skalierten Trainingsdaten erreicht.

```

1 # Optimized MLP with early stopping, higher max_iter and tuned
   # learning rate/batch size
2 mlp2 = MLPClassifier(hidden_layer_sizes=(100,100),
                      max_iter=100, alpha=1e-4, solver='adam', verbose=True,
                      random_state=912)
3
4 # Fit model
5 mlp2.fit(X_train_scaled, y_train)

```

Listing 3: MLP Classifier mit mehr Schichten

- SVC ohne Feature Extraction

Der Code initialisiert einen Support Vector Classifier mit RBF-Kernel und balancierten Klassengewichten. Das Modell wird anschließend mit den skalierten Trainingsdaten trainiert, um eine nichtlineare Klassifikationsgrenze zu erlernen.

```

1 from sklearn.svm import SVC
2
3 svc = SVC(
4     kernel="rbf",
5     C=10,
6     gamma="scale",
7     class_weight="balanced"
8 )
9
10 svc.fit(X_train_scaled, y_train)

```

Listing 4: SVC ohne Feature Extraction

- SVC mit PCA Feature Extraction:

Der Code extrahiert HOG-Features aus den Bildern, um relevante Merkmale für die Klassifikation zu gewinnen. Diese Features werden anschließend für das Training eines Support Vector Classifiers verwendet, um die Leistung des Modells zu verbessern.

```

1 from skimage.feature import hog
2
3 def extract_hog(images):
4     features = []
5     for img in images:
6         hog_feat = hog(
7             img,
8             orientations=9,
9             pixels_per_cell=(8, 8),
10            cells_per_block=(2, 2),
11            block_norm='L2-Hys'
12        )
13        features.append(hog_feat)
14    return np.array(features)

```

Listing 5: SVC mit PCA Feature Extraction

### 4.3 Code-Dokumentation

Hier sind die während der Vorarbeitung und dem Training verwendeten Code-Snippets dokumentiert:

```
1 # Libraries importieren
2 import os
3 import numpy as np
4 import matplotlib.pyplot as plt
5 from sklearn.datasets import fetch_openml
6 from sklearn.model_selection import train_test_split
7 from sklearn.neural_network import MLPClassifier
8 from sklearn.metrics import classification_report,
9                 confusion_matrix
10 from sklearn.preprocessing import StandardScaler
11 import kagglehub
```

Listing 6: Hauptlibraries

```
1 # Download latest version of dataset from Kaggle
2 path = kagglehub.dataset_download("muhammadrehan00"
3                                     "/chest-xray-dataset")
4
5 print("Path to dataset files:", path)
6
7 # Print the paths to the train and test directories
8 train_dir = os.path.join(path, "chest_xray", "train")
9 test_dir = os.path.join(path, "chest_xray", "test")
10 print("Train directory:", train_dir)
11 print("Test directory:", test_dir)
```

Listing 7: Herunterladen des Datensatzes und Pfadzuweisung

```

1 # Prepare training data
2 X_train, y_train = [], []
3
4 # Train
5 normal_X, normal_y = load_images(os.path.join(path,
6     "train/NORMAL"), "Normal")
7 pneu_X, pneu_y      = load_images(os.path.join(path,
8     "train/PNEUMONIA"), "Pneumonia")
9 tub_X, tub_y        = load_images(os.path.join(path,
10    "train/TUBERCULOSIS"), "Tuberculosis")
11
12 X_train.extend(normal_X + pneu_X + tub_X)
13 y_train.extend(normal_y + pneu_y + tub_y)
14
15 # Prepare testing data
16 X_test, y_test = [], []
17
18 # Test
19 normal_X, normal_y = load_images(os.path.join(path,
20     "test/NORMAL"), "Normal")
21 pneu_X, pneu_y      = load_images(os.path.join(path,
22     "test/PNEUMONIA"), "Pneumonia")
23 tub_X, tub_y        = load_images(os.path.join(path,
24    "test/TUBERCULOSIS"), "Tuberculosis")
25
26 X_test.extend(normal_X + pneu_X + tub_X)
27 y_test.extend(normal_y + pneu_y + tub_y)
28
29 X_test = np.array(X_test)
30 y_test = np.array(y_test)

```

Listing 8: Einteilung der Bilder in Arrays und Labels zur weiteren Verarbeitung durch das entwickelte Modell

#### 4.4 Probleme und Herausforderungen

Die Ergebnisse sowohl bei MLP Classifier als auch bei SVM waren in unserem Fall unzureichend, mit einem F1 Score von nur etwa 0,7. Dies könnte auf verschiedene Faktoren zurückzuführen sein, darunter die Komplexität der Bilder, die begrenzte Größe des Datensatzes oder die Wahl der Modelle und Hyperparameter.

Es wäre sinnvoll, in unserem Fall ein CNN (Convolutional Neural Network) zu verwenden, da diese Modelle speziell für die Verarbeitung von Bilddaten entwickelt wurden und in der Regel bessere Ergebnisse bei der Bildklassifikation erzielen.

## 5 Evaluation des Modells

|||||| HEAD Die Evaluation der Modelle erfolgte anhand verschiedener Metriken, darunter Genauigkeit, Präzision, Recall und F1-Score.

Hier sind die Ergebnisse der Evaluierung für die verschiedenen Modelle mit verschiedenen Metriken dargestellt:

- **MLP Classifier** mit `hidden_layer_sizes=(128, 128, 64)`, `max_iter=300`

Confusion Matrix:

$$\begin{bmatrix} 680 & 139 & 106 \\ 66 & 507 & 7 \\ 366 & 3 & 695 \end{bmatrix}$$

===== Die Evaluation der Modelle erfolgte anhand verschiedener Metriken, darunter Genauigkeit, Präzision, Recall und F1-Score. Zusätzlich wurden Konfusionsmatrizen erstellt, um die Leistung der Modelle visuell darzustellen.

```

1 # Vorhersagen auf dem Testset machen
2 y_pred = mlp.predict(X_test_scaled)
3
4 # Ergebnisse auswerten
5 print("Confusion Matrix:")
6 print(confusion_matrix(y_test, y_pred))
7 print("\nClassification Report:")
8 print(classification_report(y_test, y_pred))

```

Listing 9: Evaluationscode MLP Classifier

Konfusionsmatrix MLP Classifier: 
$$\begin{bmatrix} 680 & 139 & 106 \\ 66 & 507 & 7 \\ 366 & 3 & 695 \end{bmatrix}$$

	Precision	Recall	F1-score	Support
Normal	0.61	0.74	0.67	925
Pneumonia	0.78	0.87	0.83	580
Tuberculosis	0.86	0.65	0.74	1064
Accuracy			0.72	2569
Macro avg	0.75	0.75	0.74	2569
Weighted avg	0.75	0.72	0.72	2569

Classification Report:

Class	Precision	Recall	F1-Score	Support
Normal	0.61	0.74	0.67	925
Pneumonia	0.78	0.87	0.83	580
Tuberculosis	0.86	0.65	0.74	1064
<b>Accuracy</b>		0.73		2569
<b>Macro Avg</b>	0.75	0.75	0.75	2569
<b>Weighted Avg</b>	0.75	0.73	0.73	2569

- **MLP Classifier** mit `hidden_layer_sizes=(10)`, `max_iter=50`

Confusion Matrix:

$$\begin{bmatrix} 692 & 120 & 113 \\ 140 & 428 & 12 \\ 384 & 6 & 674 \end{bmatrix}$$

Classification Report:

Class	Precision	Recall	F1-Score	Support
Normal	0.57	0.75	0.65	925
Pneumonia	0.77	0.74	0.75	580
Tuberculosis	0.84	0.63	0.72	1064
<b>Accuracy</b>			0.70	2569
<b>Macro Avg</b>	0.75	0.75	0.75	2569
<b>Weighted Avg</b>	0.75	0.73	0.73	2569

- **SVM** mit `kernel="rbf"`, `C=10` ohne Feature Extraction

Confusion Matrix:

$$\begin{bmatrix} 692 & 120 & 113 \\ 140 & 428 & 12 \\ 384 & 6 & 674 \end{bmatrix}$$

Classification Report:

Class	Precision	Recall	F1-Score	Support
Normal	0.61	0.74	0.67	925
Pneumonia	0.78	0.87	0.83	580
Tuberculosis	0.86	0.65	0.74	1064
<b>Accuracy</b>		0.73		2569
<b>Macro Avg</b>	0.75	0.75	0.75	2569
<b>Weighted Avg</b>	0.75	0.73	0.73	2569

## 6 Probleme und Herausforderungen im gesamten Projekt

### 6.1 Technische Herausforderungen

### 6.2 Modellierungsprobleme

## 7 Schlussfolgerung und Reflexion

## 8 Quellen und Literaturverzeichnis

## 9 Anhang